

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN – TIN HỌC



FINAL PROJECT – LT1
TIME-DEPENDENT COVARIATES

Giảng viên: TS. Nguyễn Tiến Đạt

Sinh viên thực hiện:

STT	Họ và tên	MSSV
1	Nguyễn Thị Phương Tâm	22110193
2	Nguyễn Thị Huyền Trân	22110232

Thành phố Hồ Chí Minh, tháng 07 năm 2026

1 Phân công công việc

2 Phân công công việc

STT	Họ và tên	MSSV	Nội dung phụ trách
1	Nguyễn Thị Phương Tâm	22110193	Lý thuyết • Tổng quan về Time-dependent Covariates trong mô hình Cox. • Trình bày và minh họa với bộ dữ liệu Stanford Heart Transplant và PBC. Thực hành • Exploratory Survival Structure. • Một số ứng dụng cho models.
2	Nguyễn Thị Huyền Trân	22110232	Lý thuyết • Predictable Time-Dependent Variables. • Thí dụ minh họa với bộ dữ liệu pharmacoSmoking. Thực hành • Hazard Modelling. • Model Diagnostics.

Contents

1	Phân công công việc	1
2	Phân công công việc	1
3	Time-dependent Covariates	4
3.1	Giới thiệu	4
3.2	Cơ sở lý thuyết	4
3.2.1	Các hàm cơ bản trong phân tích sống sót	4
3.2.2	Mô hình Cox proportional hazards	5
3.2.3	Khái niệm Time-dependent Covariates	5
3.2.4	Mô hình Cox mở rộng (Extended Cox model)	5
3.2.5	Khái niệm Predictable Time Dependent Variables	6
3.3	Hazard ratio thay đổi theo thời gian	7
3.3.1	Sử dụng hàm Time Transfer	7
3.3.2	Schoenfeld residuals	8
3.3.3	Time Dependent Variables That Increase Linearly with Time	8
3.4	Stanford Heart Transplant	9
3.4.1	Giới thiệu về dataset <code>jasa</code>	9
3.4.2	Phân tích ban đầu (Naive analysis)	9
3.4.3	Landmark analysis	10
3.4.4	Mô hình Cox với tập dữ liệu rút gọn	12
3.4.5	Áp dụng trên bộ dữ liệu Stanford Heart Transplant	14
3.5	Primary Biliary Cirrhosis (PBC)	16
3.5.1	Giới thiệu về dataset PBC	16
3.5.2	Chuẩn bị dữ liệu	16
3.5.3	Xây dựng mô hình Cox	17
3.5.4	Kết quả	18
3.5.5	Một số lưu ý khi sử dụng <code>tmerge()</code>	18
3.6	Dữ liệu <code>pharmacoSmoking</code>	19
3.6.1	Giới thiệu về dữ liệu	19
3.6.2	Chuẩn bị dữ liệu	20
3.6.3	Thống kê mô tả	21

4	Time-to-default for bank loans in survival analysis	23
4.1	Data Preparing	23
4.2	Exploratory Survival Structure	25
4.2.1	Kaplan-Meier estimate	25
4.2.2	Nelson-Aalen estimate	27
4.3	Một số ứng dụng cho models	28
4.3.1	Xác định thời điểm phát cảnh báo sớm (Early Warning System - EWS) .	29
4.3.2	Diễn giải survival probability cho nhóm khách hàng có rủi ro cao	29
5	Tài liệu tham khảo	30

3 Time-dependent Covariates

3.1 Giới thiệu

Theo định nghĩa của Dirk F. Moore [1], phân tích sống sót là việc nghiên cứu về thời gian sống và các yếu tố ảnh hưởng đến chúng. Trong nghiên cứu y sinh và kinh tế, việc tìm hiểu thời gian đến khi xảy ra sự kiện mang lại giá trị chiến lược lớn hơn nhiều so với việc chỉ quan sát xem sự kiện đó có xảy ra hay không. Mục tiêu cốt lõi không chỉ là ước lượng phân phối thời gian sống sót mà còn là so sánh giữa các nhóm điều trị và làm sáng tỏ các yếu tố tác động (elucidation of factors).

Mô hình rủi ro tỷ lệ Cox (Cox Proportional Hazards model) truyền thống dựa trên một giả định khắt khe: các hiệp biến (covariates) phải được cố định tại thời điểm bắt đầu (baseline, $t = 0$). Tuy nhiên, trong các nghiên cứu kéo dài, thực tế thường biến đổi: liều lượng thuốc có thể điều chỉnh, hoặc nồng độ các hoạt chất sinh học trong máu thay đổi liên tục. Việc bỏ qua tính động này không chỉ làm mất thông tin thu thập được trong quá trình theo dõi mà còn dẫn đến sai số nghiêm trọng nếu giả thiết rủi ro tỷ lệ bị vi phạm. Do đó, tích hợp hiệp biến phụ thuộc thời gian (Time-dependent Covariates) là phương thức cần thiết để tận dụng toàn bộ dữ liệu thực tế, giúp mô hình phản ánh trung thực hơn các biến chuyển của đối tượng nghiên cứu. Để hiểu rõ cơ chế này, chúng ta cần xem xét các hàm số nền tảng của lý thuyết sống sót (survival theory).

3.2 Cơ sở lý thuyết

3.2.1 Các hàm cơ bản trong phân tích sống sót

Trong phân tích sống sót, hai khái niệm được sử dụng thường xuyên là **Survival Function** và **Hazard Function**. Đây là cơ sở để xây dựng các mô hình phân tích sống sót, trong đó có mô hình Cox proportional hazards.

Survival Function, ký hiệu là $S(t)$, biểu diễn xác suất một đối tượng vẫn chưa xảy ra biến cố tại thời điểm t . Hàm này nhận giá trị bằng 1 tại thời điểm bắt đầu theo dõi và giảm dần theo thời gian.

$$S(t) = \Pr(T > t) \quad (1.1)$$

Trong đó, T là thời gian xảy ra biến cố.

Hazard Function, ký hiệu là $h(t)$, biểu diễn mức nguy cơ xảy ra biến cố tại thời điểm t , với điều kiện đối tượng vẫn còn được theo dõi ngay trước thời điểm đó. Hàm này được định nghĩa như sau

$$h(t) = \lim_{\delta \rightarrow 0} \frac{\Pr(t < T < t + \delta \mid T > t)}{\delta}. \quad (1.2)$$

Khác với xác suất thông thường, Hazard Function biểu diễn tốc độ xảy ra biến cố tại một thời điểm nên không bị giới hạn trong khoảng từ 0 đến 1.

3.2.2 Mô hình Cox proportional hazards

Mô hình Cox proportional hazards được sử dụng để đánh giá ảnh hưởng của các biến giải thích đến nguy cơ xảy ra biến cố. Một ưu điểm của mô hình này là không cần giả thiết trước dạng của hàm nguy cơ cơ sở.

Hàm nguy cơ của một đối tượng được biểu diễn dưới dạng

$$h(t|z) = h_0(t)e^{z\beta}. \quad (1.3)$$

Trong đó:

- $h_0(t)$ là hàm nguy cơ cơ sở (baseline hazard);
- z là vector các biến giải thích;
- β là vector hệ số hồi quy cần ước lượng.

Mô hình Cox không chứa hệ số chặn (intercept) vì phần này đã được gộp vào hàm nguy cơ cơ sở $h_0(t)$.

Mô hình Cox được xây dựng dựa trên giả định proportional hazard. Giả định này cho rằng tỷ số giữa hàm nguy cơ của hai đối tượng bất kỳ không thay đổi theo thời gian. Nói cách khác, ảnh hưởng của các biến giải thích lên nguy cơ xảy ra biến cố được giả sử là không đổi trong toàn bộ thời gian theo dõi.

3.2.3 Khái niệm Time-dependent Covariates

Trong mô hình Cox thông thường, các biến giải thích được giả sử có giá trị cố định trong suốt thời gian theo dõi. Tuy nhiên, trong nhiều nghiên cứu thực tế, một số biến có thể thay đổi theo thời gian, chẳng hạn như tình trạng điều trị, kết quả xét nghiệm hoặc các chỉ số sinh học. Những biến này được gọi là **Time-Dependent Covariates**.

Theo Moore [1], khi xuất hiện biến phụ thuộc thời gian, tại mỗi thời điểm xảy ra biến cố, mô hình chỉ sử dụng giá trị hiện tại của biến đối với các đối tượng còn nằm trong tập nguy cơ (risk set). Giá trị của biến phải được xác định từ những thông tin đã quan sát được trước thời điểm đó và không được sử dụng thông tin của tương lai trong quá trình xây dựng mô hình.

3.2.4 Mô hình Cox mở rộng (Extended Cox model)

Khi đưa biến phụ thuộc thời gian vào mô hình, cấu trúc của mô hình Cox vẫn được giữ nguyên. Điểm khác biệt là giá trị của biến giải thích được cập nhật theo thời gian thay vì giữ cố định trong suốt quá trình theo dõi.

Khi đó, hàm nguy cơ của đối tượng được viết dưới dạng

$$h(t) = h_0(t)e^{z_k(t_i)\beta}, \quad (1.4)$$

trong đó:

- $h(t)$ là hàm nguy cơ tại thời điểm t ;
- $h_0(t)$ là hàm nguy cơ cơ sở;
- $z_k(t_i)$ là giá trị của biến phụ thuộc thời gian của đối tượng thứ k tại thời điểm xảy ra biến cố t_i ;
- β là hệ số hồi quy cần ước lượng.

Do giá trị của biến giải thích thay đổi theo thời gian, hàm hợp lý từng phần cũng được điều chỉnh tương ứng. Hàm hợp lý từng phần được viết dưới dạng

$$L(\beta) = \prod_{i=1}^D \frac{\psi_{ii}}{\sum_{k \in R_i} \psi_{ki}}, \quad (1.5)$$

trong đó:

$$\psi_{ki} = e^{z_k(t_i)\beta}. \quad (1.6)$$

Ở đây:

- D là tổng số biến cố được quan sát;
- R_i là tập nguy cơ tại thời điểm xảy ra biến cố thứ i ;
- ψ_{ki} biểu diễn mức đóng góp của đối tượng thứ k trong tập nguy cơ tại thời điểm t_i .

Khác với mô hình Cox thông thường, giá trị của ψ_{ki} không còn cố định trong suốt quá trình theo dõi. Tại mỗi thời điểm xảy ra biến cố, giá trị này được tính lại dựa trên giá trị hiện tại của biến phụ thuộc thời gian. Vì vậy, thành phần ở mẫu số của hàm hợp lý từng phần cũng thay đổi theo từng thời điểm xảy ra biến cố. Điều này cho phép mô hình phản ánh sự thay đổi của các biến giải thích trong quá trình theo dõi mà vẫn giữ nguyên nguyên lý xây dựng của mô hình Cox.

3.2.5 Khái niệm Predictable Time Dependent Variables

Giả sử hàm hệ số được biểu diễn dưới dạng:

$$\beta(t) = \beta_1 + \beta_2 g(t), \quad (1.7)$$

thì mô hình (1.3) trở thành:

$$h(t | z) = h_0(t) \exp\{\beta_1 z + \beta_2 z g(t)\}.$$

Trong mô hình trên, biến mới

$$zg(t)$$

được gọi là **predictable time dependent variable**. Biến này được tạo ra bởi người phân tích dựa trên covariate z và một hàm thời gian $g(t)$ được xác định trước.

Từ “predictable” có nghĩa là tại thời điểm t , giá trị của biến phải được xác định từ thông tin đã biết trước hoặc ngay tại thời điểm đó. Không được sử dụng thông tin xuất hiện trong tương lai.

3.3 Hazard ratio thay đổi theo thời gian

Đối với covariate nhị phân z , hazard ratio giữa nhóm $z = 1$ và nhóm $z = 0$ tại thời điểm t là:

$$HR(t) = \exp\{\beta_1 + \beta_2 g(t)\}.$$

Khác với Cox PH model thông thường, $HR(t)$ không nhất thiết là một hằng số.

Nếu chọn:

$$g(t) = \log(t),$$

thì:

$$HR(t) = \exp\{\beta_1 + \beta_2 \log(t)\}.$$

Cách diễn giải:

- Nếu $\beta_2 = 0$, hazard ratio không thay đổi theo thời gian.
- Nếu $\beta_2 > 0$, log hazard ratio tăng theo thời gian.
- Nếu $\beta_2 < 0$, log hazard ratio giảm theo thời gian.

3.3.1 Sử dụng hàm Time Transfer

Package `survival` cung cấp hàm `tt()` trong `coxph()` để tạo predictable time dependent variables.

Cấu trúc tổng quát:

```
fit_tt <- coxph(  
  Surv(time, status) ~  
    x + tt(x),  
  data = data_name,  
  tt = function(x, t, ...) {  
    x * log(t)  
  }  
)
```

Trong đó:

- x biểu diễn ảnh hưởng chính của covariate.
- $tt(x)$ biểu diễn phần ảnh hưởng thay đổi theo thời gian.
- Hàm $x * \log(t)$ xác định dạng thay đổi theo thời gian.

Mô hình tương ứng là:

$$h(t) = h_0(t) \exp\{\beta_1 x + \beta_2 x \log(t)\}.$$

Việc lựa chọn hàm $g(t)$ cần dựa trên kiến thức chuyên môn và kết quả kiểm tra giả định proportional hazards.

3.3.2 Schoenfeld residuals

Schoenfeld residuals thường được sử dụng để đánh giá giả định proportional hazards:

```
ph_test <- cox.zph(fit_cox)

ph_test
plot(ph_test)
```

Cách đọc kết quả:

- p-value lớn hơn 0.05: chưa có bằng chứng rõ ràng cho thấy covariate vi phạm giả định PH.
- p-value nhỏ hơn 0.05: ảnh hưởng của covariate có thể thay đổi theo thời gian.
- Đường smooth trên residual plot có thể gợi ý dạng của hàm $g(t)$.

Việc thêm time-dependent effect không nên chỉ dựa vào p-value. Cần kết hợp:

- biểu đồ Schoenfeld residuals;
- kiến thức về quá trình nghiên cứu;
- khả năng diễn giải của mô hình;
- mức độ phù hợp của hàm thời gian được chọn.

3.3.3 Time Dependent Variables That Increase Linearly with Time

Một covariate có thể tăng đều theo thời gian. Ví dụ, tuổi hiện tại của bệnh nhân được viết:

$$z(t) = z(0) + t,$$

trong đó $z(0)$ là tuổi tại thời điểm bắt đầu nghiên cứu.

Thay vào Cox model:

$$h(t) = h_0(t) \exp\{\beta[z(0) + t]\}.$$

Ta có:

$$h(t) = [h_0(t) \exp(\beta t)] \exp\{\beta z(0)\}.$$

Thành phần $\exp(\beta t)$ giống nhau đối với tất cả đối tượng tại cùng một thời điểm và được hấp thụ vào baseline hazard. Vì vậy, sử dụng tuổi hiện tại thay cho tuổi tại thời điểm bắt đầu không làm thay đổi hệ số Cox.

Kết quả này áp dụng khi covariate tăng tuyến tính với cùng tốc độ đối với mọi đối tượng. Nếu covariate thay đổi không đều hoặc thay đổi khác nhau giữa các đối tượng, kết quả trên không còn đúng

3.4 Stanford Heart Transplant

3.4.1 Giới thiệu về dataset jasa

Để minh họa cho việc sử dụng biến phụ thuộc thời gian trong mô hình Cox, Moore sử dụng bộ dữ liệu **Stanford Heart Transplant** (dữ liệu `jasa` trong packages `survival`). Bộ dữ liệu này ghi nhận thời gian sống của các bệnh nhân mắc bệnh tim giai đoạn cuối và theo dõi việc họ có được ghép tim trong quá trình điều trị hay không.

Biến được quan tâm trong ví dụ là `transplant`. Biến này nhận giá trị bằng 1 đối với bệnh nhân đã được ghép tim và bằng 0 đối với những bệnh nhân chưa được ghép. Để đánh giá ảnh hưởng của biến này, trước hết mô hình Cox được xây dựng bằng cách xem `transplant` là một biến cố định. Sau đó, dữ liệu được chuyển sang định dạng **start–stop** và mô hình Cox mở rộng được áp dụng để xử lý đúng bản chất của biến phụ thuộc thời gian (time-dependent covariates).

3.4.2 Phân tích ban đầu (Naive analysis)

Ban đầu, biến `transplant` được xem như một biến cố định và mô hình Cox được xây dựng bằng đoạn lệnh sau

```
result.heart <- coxph(Surv(futime, fustat) ~ transplant + age +
                      surgery, data = jasa)

summary(result.heart)
```

```
## Call:
## coxph(formula = Surv(futime, fustat) ~ transplant + age + surgery,
##       data = jasa)
##
## n= 103, number of events= 75
##
##               coef exp(coef) se(coef)      z Pr(>|z|)
## transplant -1.71711  0.17958  0.27853 -6.165 7.05e-10 ***
```

```
## age          0.05889    1.06065    0.01505    3.913 9.12e-05 ***
## surgery     -0.41902    0.65769    0.37118   -1.129    0.259
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##              exp(coef) exp(-coef) lower .95 upper .95
## transplant    0.1796     5.5684     0.1040     0.310
## age           1.0607     0.9428     1.0298     1.092
## surgery       0.6577     1.5205     0.3177     1.361
##
## Concordance= 0.732 (se = 0.031 )
## Likelihood ratio test= 45.85 on 3 df,  p=6e-10
## Wald test              = 47.15 on 3 df,  p=3e-10
## Score (logrank) test = 52.63 on 3 df,  p=2e-11
```

Kết quả thu được cho thấy hệ số của biến **transplant** bằng -1.717 và có giá trị **p-value** rất nhỏ. Nếu chỉ dựa vào kết quả này, có thể kết luận rằng ghép tim giúp làm giảm nguy cơ tử vong và kéo dài thời gian sống của bệnh nhân.

Tuy nhiên, cách phân tích trên chưa phản ánh đúng bản chất của dữ liệu. Trong thực tế, một bệnh nhân chỉ có thể được ghép tim nếu họ còn sống đến thời điểm có tim hiến. Điều này có nghĩa là những bệnh nhân được ghép tim đã phải sống đủ lâu để nhận được ca ghép, trong khi nhiều bệnh nhân khác tử vong trước thời điểm đó và không bao giờ có cơ hội được ghép.

Do đó, nếu xem **transplant** là một biến cố định ngay từ thời điểm bắt đầu nghiên cứu thì nhóm bệnh nhân được ghép tim mặc nhiên có lợi thế về thời gian sống. Kết quả ước lượng vì vậy có thể bị sai lệch và làm cho hiệu quả của việc ghép tim bị đánh giá cao hơn thực tế.

3.4.3 Landmark analysis

Để hạn chế sai lệch trên, Moore giới thiệu phương pháp **Landmark Analysis**.

Ý tưởng của phương pháp là lựa chọn một thời điểm mốc (landmark time) và chỉ đưa vào phân tích những bệnh nhân còn sống tại thời điểm này. Sau đó, các bệnh nhân được chia thành hai nhóm dựa trên tình trạng ghép tim trước thời điểm mốc.

Trong ví dụ này, thời điểm mốc được chọn là 30 ngày. Chỉ những bệnh nhân sống ít nhất 30 ngày mới được giữ lại trong phân tích. Trong số các bệnh nhân này, người đã được ghép tim trong vòng 30 ngày được xếp vào nhóm ghép tim, còn những bệnh nhân chưa được ghép trong khoảng thời gian này được xếp vào nhóm không ghép tim.

Biến mới được tạo ra có tên **transplant30**. Sau khi được xác định tại thời điểm 30 ngày, giá trị của biến này được giữ cố định trong toàn bộ quá trình phân tích tiếp theo.

Việc xây dựng mô hình được thực hiện như sau

```
ind30 <- jasa$futime >= 30
transplant30 <- {jasa$transplant == 1} & {jasa$wait.time < 30}
```

```
summary(coxph(Surv(futime, fustat) ~ transplant30 + age +
             surgery, data=jasa, subset=ind30 ))
```

```
## Call:
## coxph(formula = Surv(futime, fustat) ~ transplant30 + age + surgery,
##       data = jasa, subset = ind30)
##
## n= 79, number of events= 52
##
##               coef exp(coef) se(coef)      z Pr(>|z|)
## transplant30TRUE -0.04214    0.95874  0.28377 -0.148   0.8820
## age              0.03720    1.03790  0.01714  2.170   0.0300 *
## surgery          -0.81966    0.44058  0.41297 -1.985   0.0472 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##               exp(coef) exp(-coef) lower .95 upper .95
## transplant30TRUE      0.9587      1.0430      0.5497      1.6720
## age                   1.0379      0.9635      1.0036      1.0734
## surgery               0.4406      2.2697      0.1961      0.9898
##
## Concordance= 0.618 (se = 0.044 )
## Likelihood ratio test= 9.5 on 3 df,  p=0.02
## Wald test              = 8.61 on 3 df,  p=0.03
## Score (logrank) test = 8.94 on 3 df,  p=0.03
```

Kết quả cho thấy hệ số của biến `transplant30` giảm đáng kể về giá trị tuyệt đối và không còn có ý nghĩa thống kê. Điều này cho thấy kết luận từ mô hình ban đầu phần lớn chịu ảnh hưởng bởi cách xử lý biến `transplant` như một biến cố định.

Mặc dù Landmark Analysis giúp giảm sai lệch do xử lý biến `transplant` như một biến cố định, phương pháp này vẫn làm mất một phần dữ liệu và kết quả còn phụ thuộc vào thời điểm mốc được lựa chọn.

Để khắc phục hạn chế này, Moore giới thiệu cách xây dựng mô hình Cox với biến phụ thuộc thời gian. Trước khi áp dụng cho toàn bộ bộ dữ liệu Stanford Heart Transplant, tác giả sử dụng một tập dữ liệu rút gọn gồm 6 bệnh nhân nhằm minh họa cách chuyển dữ liệu từ dạng thông thường sang dạng **start-stop**.

Để minh họa cơ chế triển khai, một tập dữ liệu rút gọn gồm 6 bệnh nhân (3 người được ghép tim và 3 người không ghép tim) được trích xuất từ tập dữ liệu `jasa` trong R:

```
# Khởi tạo tập dữ liệu rút gọn heart.simple từ jasa
id <- 1:nrow(jasa)
jasaT <- data.frame(id, jasa)
id.simple <- c(2, 5, 10, 12, 28, 95)
heart.simple <- jasaT[id.simple, c(1, 10, 9, 6, 11)]
```

Trong tập dữ liệu này, tất cả 6 bệnh nhân đều tử vong trong thời gian theo dõi ($fustat = 1$). Nếu tiến hành ước lượng nguy cơ (nghĩa là bỏ qua đặc tính phụ thuộc thời gian của biến `transplant`), mô hình Cox sẽ cho kết quả sai lệch như sau:

```
summary(coxph(Surv(futime, fustat) ~ transplant, data = heart.simple))

## Call:
## coxph(formula = Surv(futime, fustat) ~ transplant, data = heart.simple)
##
##      n= 6, number of events= 6
##
##              coef exp(coef) se(coef)      z Pr(>|z|)
## transplant -1.6878    0.1849   1.1718 -1.44    0.15
##
##              exp(coef) exp(-coef) lower .95 upper .95
## transplant    0.1849      5.408    0.0186    1.838
##
## Concordance= 0.733  (se = 0.077 )
## Likelihood ratio test= 2.47  on 1 df,   p=0.1
## Wald test               = 2.07  on 1 df,   p=0.1
## Score (logrank) test = 2.56  on 1 df,   p=0.1
```

3.4.4 Mô hình Cox với tập dữ liệu rút gọn

Như đã trình bày ở trên, việc xem `transplant` là một biến cố định có thể dẫn đến sai lệch trong quá trình ước lượng. Để phản ánh đúng thời điểm bệnh nhân được ghép tim, Moore xây dựng `transplant` như một biến phụ thuộc thời gian (Time-Dependent Covariate).

Với cách tiếp cận này, dữ liệu không còn được biểu diễn theo dạng một dòng cho mỗi bệnh nhân. Thay vào đó, thời gian theo dõi được chia thành các khoảng (*start*, *stop*], trong đó giá trị của biến `transplant` được giữ cố định trong từng khoảng thời gian.

Đối với bệnh nhân không được ghép tim, toàn bộ thời gian theo dõi chỉ tạo thành một khoảng và biến `transplant` luôn nhận giá trị bằng 0. Đối với bệnh nhân được ghép tim, dữ liệu được chia thành hai khoảng. Trước thời điểm ghép tim, `transplant = 0`; sau thời điểm ghép tim, giá trị của biến được cập nhật thành `transplant = 1`.

Trong gói `survival`, việc chuyển đổi dữ liệu sang định dạng **start–stop** được thực hiện bằng hàm `tmerge()`.

```
sdata <- tmerge(heart.simple, heart.simple, id=id,
               death=event(futime, fustat),
               transpl=tdc(wait.time))
heart.simple.counting <- sdata[,-(2:5)] # drop columns 2 through 5
heart.simple.counting
```

```
##   id tstart tstop death transpl
## 1  2      0     5     1       0
## 2  5      0    17     1       0
## 3 10      0    11     0       0
## 4 10     11    57     1       1
## 5 12      0     7     1       0
## 6 28      0    70     0       0
## 7 28     70    71     1       1
## 8 95      0     1     0       0
## 9 95      1    15     1       1
```

Bảng trên cho thấy sau khi chuyển đổi sang định dạng start–stop, một số bệnh nhân được biểu diễn bởi nhiều dòng dữ liệu thay vì một dòng như ban đầu. Các cột `tstart` và `tstop` xác định khoảng thời gian theo dõi của từng quan sát, trong khi biến `transpl` được cập nhật từ 0 sang 1 tại thời điểm bệnh nhân được ghép tim. Điều này giúp mô hình Cox mở rộng sử dụng đúng giá trị của biến tại từng thời điểm trong quá trình theo dõi.

Tiếp theo ta xây dựng mô hình Cox bằng hàm `coxph()` với đối tượng `Surv(start, stop, event)`. Cách biểu diễn này cho phép mô hình cập nhật giá trị của biến `transplant` theo đúng thời điểm xảy ra ghép tim. Nhờ đó, mỗi bệnh nhân chỉ được xem là đã ghép tim kể từ thời điểm thực sự nhận được ca ghép, thay vì được xem là đã ghép ngay từ đầu nghiên cứu.

```
summary(coxph(Surv(tstart, tstop, death) ~ transpl,
               data=heart.simple.counting))
```

```
## Call:
## coxph(formula = Surv(tstart, tstop, death) ~ transpl, data = heart.simple.counting)
##
##      n= 9, number of events= 6
##
##              coef exp(coef) se(coef)      z Pr(>|z|)
## transpl 0.2846     1.3292   0.9609 0.296    0.767
##
##              exp(coef) exp(-coef) lower .95 upper .95
## transpl      1.329      0.7523   0.2021      8.74
##
## Concordance= 0.5  (se = 0.082 )
## Likelihood ratio test= 0.09  on 1 df,   p=0.8
## Wald test               = 0.09  on 1 df,   p=0.8
## Score (logrank) test = 0.09  on 1 df,   p=0.8
```

Trong đoạn lệnh trên, `Surv(tstart, tstop, death)` biểu diễn thời gian theo dõi dưới dạng **start–stop**, còn biến `transpl` được đưa vào mô hình như một biến phụ thuộc thời gian. Nhờ đó, giá trị của biến được cập nhật tại đúng thời điểm bệnh nhân được ghép tim.

Kết quả của mô hình được trình bày ở trên. So với mô hình Cox thông thường, hệ số hồi quy của biến `transpl` thay đổi sau khi dữ liệu được xử lý theo định dạng **start–stop**. Điều này cho

thấy việc cập nhật giá trị của biến theo thời gian có ảnh hưởng trực tiếp đến kết quả ước lượng của mô hình.

Trong ví dụ này, mục đích chính của tập dữ liệu `heart.simple` là minh họa cách biểu diễn dữ liệu và xây dựng mô hình Cox với biến phụ thuộc thời gian. Sau khi hiểu cơ chế hoạt động trên bộ dữ liệu rút gọn, mô hình sẽ được áp dụng cho toàn bộ bộ dữ liệu **Stanford Heart Transplant** ở phần tiếp theo.

3.4.5 Áp dụng trên bộ dữ liệu Stanford Heart Transplant

Sau khi minh họa trên tập dữ liệu rút gọn, mô hình Cox với biến phụ thuộc thời gian được áp dụng cho toàn bộ bộ dữ liệu **Stanford Heart Transplant**. Trước khi xây dựng mô hình, dữ liệu được xử lý để phù hợp với định dạng **start–stop**.

Các biến không cần thiết được loại bỏ để tạo tập dữ liệu tạm thời. Ngoài ra, thời gian tử vong bằng 0 được thay thế bằng 0.5 ngày nhằm tránh khoảng thời gian theo dõi có độ dài bằng 0. Trường hợp thời điểm ghép tim trùng với thời điểm xảy ra biến cố cũng được điều chỉnh bằng cách giảm thời gian ghép đi 0.5 ngày để tránh xảy ra hai sự kiện tại cùng một thời điểm.

Quá trình chuẩn bị dữ liệu được thực hiện bằng các lệnh sau:

```
tdata <- jasa[, -c(1:4, 11:14)]

tdata$futime <- pmax(.5, tdata$futime)

indx <- (tdata$wait.time == tdata$futime) &
        !is.na(tdata$wait.time)

tdata$wait.time[indx] <- tdata$wait.time[indx] - .5

tdata$id <- seq_len(nrow(tdata))

sdata <- tmerge(tdata, tdata, id = id,
               death = event(futime, fustat),
               trans = tdc(wait.time))

jasa.counting <- sdata[, c(7:11, 2:3)]

head(jasa.counting)
```

##	id	tstart	tstop	death	trans	surgery	age
## 1	1	0	49	1	0	0	30.84463
## 2	2	0	5	1	0	0	51.83573
## 3	3	0	15	1	1	0	54.29706
## 4	4	0	35	0	0	0	40.26283
## 5	4	35	38	1	1	0	40.26283
## 6	5	0	17	1	0	0	20.78576

Sau khi chuyển đổi, bộ dữ liệu `jaso.counting` được biểu diễn theo định dạng **start–stop**. Đối với những bệnh nhân không được ghép tim, dữ liệu chỉ gồm một khoảng thời gian từ khi bắt đầu theo dõi đến khi xảy ra biến cố hoặc kết thúc nghiên cứu. Đối với bệnh nhân được ghép tim, dữ liệu được chia thành hai khoảng thời gian. Khoảng thứ nhất tương ứng với giai đoạn trước khi ghép tim, khi biến `trans` nhận giá trị bằng 0. Khoảng thứ hai bắt đầu từ thời điểm ghép tim đến khi kết thúc theo dõi, khi giá trị của biến được cập nhật thành 1.

Sau khi hoàn thành bước chuẩn bị dữ liệu, mô hình Cox với biến phụ thuộc thời gian được xây dựng như sau:

```
summary(
  coxph(
    Surv(tstart, tstop, death) ~ trans + surgery + age,
    data = jaso.counting
  )
)
```

```
## Call:
## coxph(formula = Surv(tstart, tstop, death) ~ trans + surgery +
##       age, data = jaso.counting)
##
##      n= 170, number of events= 75
##
##              coef exp(coef) se(coef)      z Pr(>|z|)
## trans      0.01405   1.01415  0.30822  0.046   0.9636
## surgery -0.77326   0.46150  0.35966 -2.150   0.0316 *
## age       0.03055   1.03103  0.01389  2.199   0.0279 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##              exp(coef) exp(-coef) lower .95 upper .95
## trans           1.0142     0.9860    0.5543    1.8555
## surgery          0.4615     2.1668    0.2280    0.9339
## age             1.0310     0.9699    1.0033    1.0595
##
## Concordance= 0.599 (se = 0.036 )
## Likelihood ratio test= 10.72 on 3 df,  p=0.01
## Wald test              = 9.68 on 3 df,  p=0.02
## Score (logrank) test = 10 on 3 df,  p=0.02
```

Kết quả mô hình cho thấy biến `trans` có hệ số hồi quy bằng **0.01405**, tương ứng với **hazard ratio = 1.01415** và **p-value = 0.9636**. Với mức ý nghĩa 5%, biến `trans` không có ý nghĩa thống kê trong mô hình. Điều này cho thấy chưa có đủ bằng chứng để kết luận rằng việc ghép tim làm thay đổi nguy cơ tử vong sau khi biến này được xử lý đúng dưới dạng biến phụ thuộc thời gian.

Đối với hai biến còn lại, **surgery** có hệ số hồi quy âm và có ý nghĩa thống kê ($p\text{-value} = 0.0316$), trong khi biến **age** có hệ số hồi quy dương và cũng có ý nghĩa thống kê ($p\text{-value} = 0.0279$).

So sánh với mô hình Cox thông thường cho thấy kết quả của biến **trans** đã thay đổi đáng kể. Khi **trans** được xem là biến cố định, mô hình cho thấy ghép tim làm giảm nguy cơ tử vong. Tuy nhiên, sau khi chuyển sang mô hình Cox với biến phụ thuộc thời gian, ảnh hưởng này không còn có ý nghĩa thống kê. Kết quả này phù hợp với kết quả của phương pháp **Landmark Analysis**, nhưng có ưu điểm là không phải loại bỏ các bệnh nhân tử vong trước thời điểm mốc. Nhờ sử dụng toàn bộ dữ liệu trong nghiên cứu, mô hình Cox mở rộng phản ánh đúng hơn quá trình theo dõi của từng bệnh nhân và hạn chế sai lệch do xử lý không đúng bản chất của biến **trans**.

3.5 Primary Biliary Cirrhosis (PBC)

3.5.1 Giới thiệu về dataset PBC

Sau ví dụ về dữ liệu ghép tim, ta tiếp tục minh họa việc sử dụng biến phụ thuộc thời gian trên bộ dữ liệu **Primary Biliary Cirrhosis (PBC)**. Đây là bộ dữ liệu theo dõi bệnh nhân mắc bệnh xơ gan mật nguyên phát nhằm nghiên cứu các yếu tố ảnh hưởng đến thời gian sống.

Bộ dữ liệu được chia thành hai phần:

- **pbcc**: chứa thông tin ban đầu của bệnh nhân và trạng thái theo dõi;
- **pbccseq**: chứa các kết quả xét nghiệm được đo nhiều lần trong quá trình theo dõi.

Không giống ví dụ ghép tim, biến phụ thuộc thời gian trong bộ dữ liệu này không phải là biến nhị phân mà là các chỉ số xét nghiệm được cập nhật nhiều lần trong suốt quá trình nghiên cứu.

Các biến được cập nhật theo thời gian gồm:

- **ascites**: tình trạng cổ trướng;
- **bili**: nồng độ bilirubin;
- **albumin**: nồng độ albumin;
- **prottime**: thời gian prothrombin;
- **alk.phos**: phosphatase kiềm.

3.5.2 Chuẩn bị dữ liệu

Đầu tiên, ta tạo một bộ dữ liệu chỉ gồm các bệnh nhân thuộc thử nghiệm lâm sàng và giữ lại một số biến nền cần thiết.

```
temp <- subset(  
  pbcc,  
  id <= 312,  
  select = c(id:sex, stage)  
)
```

Sau đó, dữ liệu được chuyển sang định dạng **start–stop** bằng hàm `tmerge()`. Trong lần gọi đầu tiên, hàm xác định khoảng thời gian theo dõi và biến cố tử vong.

```
pbc2 <- tmerge(  
  temp,  
  temp,  
  id = id,  
  death = event(time, status)  
)
```

Tiếp theo, các chỉ số xét nghiệm được cập nhật vào dữ liệu theo đúng thời điểm đo.

```
pbc2 <- tmerge(  
  pbc2,  
  pbcseq,  
  id = id,  
  ascites = tdc(day, ascites),  
  bili = tdc(day, bili),  
  albumin = tdc(day, albumin),  
  protime = tdc(day, protime),  
  alk.phos = tdc(day, alk.phos)  
)
```

Sau bước này, bộ dữ liệu `pbc2` đã được chuyển sang định dạng **start–stop**. Mỗi khi một chỉ số xét nghiệm thay đổi, `tmerge()` sẽ tạo thêm một khoảng thời gian mới và cập nhật giá trị của biến tại thời điểm tương ứng.

3.5.3 Xây dựng mô hình Cox

Để đánh giá ảnh hưởng của việc cập nhật các chỉ số xét nghiệm theo thời gian, tài liệu xây dựng hai mô hình Cox.

Mô hình thứ nhất chỉ sử dụng các giá trị xét nghiệm tại thời điểm ban đầu.

```
fit1 <- coxph(  
  Surv(time, status == 2) ~  
    log(bili) + log(protime),  
  data = pbc  
)
```

Mô hình thứ hai sử dụng dữ liệu đã được chuyển sang định dạng **start–stop**, trong đó giá trị của các biến được cập nhật trong suốt thời gian theo dõi.

```
fit2 <- coxph(
  Surv(tstart, tstop, death == 2) ~
    log(bili) + log(protime),
  data = pbc2
)
```

Các hệ số hồi quy của hai mô hình được so sánh bằng lệnh:

```
rbind(
  "Baseline model" = coef(fit1),
  "Time-dependent model" = coef(fit2)
)
```

```
##               log(bili) log(protime)
## Baseline model    0.930592    2.890573
## Time-dependent model 1.241214    3.983400
```

3.5.4 Kết quả

Kết quả thu được như sau.

Mô hình	log(bili)	log(protime)
Baseline model	0.930592	2.890573
Time-dependent model	1.241214	3.983400

Có thể thấy hệ số hồi quy của cả hai biến đều lớn hơn khi sử dụng mô hình có biến phụ thuộc thời gian.

Ta thấy rằng bệnh xơ gan mật nguyên phát tiến triển dần theo thời gian và đi kèm với sự thay đổi của các chỉ số bilirubin và prothrombin. Mô hình chỉ sử dụng giá trị ban đầu chỉ phản ánh tình trạng bệnh tại thời điểm bắt đầu nghiên cứu. Trong khi đó, mô hình Cox với biến phụ thuộc thời gian cập nhật các chỉ số xét nghiệm trong suốt quá trình theo dõi nên phản ánh tốt hơn diễn biến của bệnh.

3.5.5 Một số lưu ý khi sử dụng `tmerge()`

Theo mặc định, hàm `tmerge()` sẽ bỏ qua các lần cập nhật có thời điểm hoặc giá trị bị thiếu (NA). Riêng đối với trường hợp giá trị của biến bị thiếu nhưng thời điểm đo vẫn được ghi nhận, hàm sử dụng giá trị quan sát gần nhất trước đó để tiếp tục cập nhật. Cách xử lý này được gọi là **last value carried forward**.

Nếu không muốn sử dụng cơ chế này, có thể bổ sung tùy chọn

```
options = list(na.rm = FALSE)
```

khi gọi `tmerge()`. Khi đó, các khoảng thời gian có giá trị thiếu sẽ được giữ nguyên là `NA`.

Để kiểm tra quá trình chuyển đổi dữ liệu, ta sử dụng lệnh [2]:

```
attr(pbc2, "tcount")
```

##	early	late	gap	within	boundary	leading	trailing	tied	missid
## death	0	0	0	0	0	0	312	0	0
## ascites	0	131	0	1442	0	312	0	0	0
## bili	0	138	0	53	1442	312	0	0	0
## albumin	0	138	0	0	1495	312	0	0	0
## protime	0	138	0	0	1495	312	0	0	0
## alk.phos	0	131	0	0	1442	312	0	0	0

Bảng kết quả cho biết số lần cập nhật được thêm vào trong từng giai đoạn của quá trình theo dõi và số lần cập nhật bị bỏ qua. Đây là công cụ giúp kiểm tra việc xây dựng dữ liệu theo định dạng **start-stop**.

Lưu ý rằng không nên tự ý kéo dài thời gian theo dõi của một số bệnh nhân chỉ vì họ có thêm kết quả xét nghiệm sau thời điểm kết thúc nghiên cứu. Nếu chỉ cập nhật thời gian theo dõi cho một số đối tượng mà không cập nhật đầy đủ thông tin biến cố cho toàn bộ nghiên cứu, tập nguy cơ (*risk set*) của mô hình Cox sẽ không còn phản ánh đúng quá trình theo dõi. Vì vậy, `tmerge()` chỉ sử dụng các lần cập nhật nằm trong khoảng thời gian theo dõi đã được xác định ban đầu.

Nhận xét:

- Ví dụ trên cho thấy mô hình Cox với biến phụ thuộc thời gian không chỉ áp dụng cho các biến trạng thái như ghép tim mà còn có thể sử dụng đối với các chỉ số lâm sàng được đo nhiều lần trong quá trình theo dõi.
- Việc cập nhật giá trị của các biến tại đúng thời điểm đo giúp mô hình khai thác đầy đủ thông tin của dữ liệu và phản ánh chính xác hơn sự thay đổi của tình trạng bệnh trong suốt quá trình nghiên cứu.

3.6 Dữ liệu `pharmacoSmoking`

3.6.1 Giới thiệu về dữ liệu

Dữ liệu `pharmacoSmoking` thuộc package `asaur`. Nghiên cứu so sánh hai phương pháp hỗ trợ cai thuốc lá:

- `patchOnly`: chỉ sử dụng nicotine patch;

- `combination`: sử dụng liệu pháp kết hợp.

Biến kết quả là thời gian từ khi bắt đầu nghiên cứu đến khi người tham gia tái hút thuốc.

Các biến chính:

Biến	Ý nghĩa
<code>ttr</code>	Số ngày đến khi tái hút thuốc hoặc kết thúc theo dõi
<code>relapse</code>	1: tái hút thuốc; 0: kiểm duyệt
<code>grp</code>	Nhóm điều trị
<code>age</code>	Tuổi
<code>gender</code>	Giới tính
<code>race</code>	Chủng tộc
<code>employment</code>	Tình trạng việc làm

Trong ví dụ này, `grp` được xác định tại thời điểm bắt đầu nên không phải là covariate thay đổi trạng thái. Tuy nhiên, ảnh hưởng của nhóm điều trị lên hazard tái hút thuốc có thể thay đổi theo thời gian. Vì vậy, ta xây dựng predictable time dependent variable:

$$\text{grp} \times \log(t + 1).$$

3.6.2 Chuẩn bị dữ liệu

```
data(
  "pharmacoSmoking",
  package = "asaur"
)

smoking <- pharmacoSmoking

smoking$grp <- factor(
  smoking$grp,
  levels = c(
    "patchOnly",
    "combination"
  )
)

smoking$grp_num <- ifelse(
  smoking$grp == "combination",
  1,
  0
)
```

```
smoking$gender <- factor(smoking$gender)
```

```
head(smoking)
```

```
##      id ttr relapse      grp age gender      race employment yearsSmoking
## 1  21 182      0  patchOnly 36  Male    white          ft          26
## 2 113  14      1  patchOnly 41  Male    white          other         27
## 3  39   5      1 combination 25 Female    white          other         12
## 4  80 16      1 combination 54  Male    white          ft          39
## 5  87  0      1 combination 45  Male    white          other         30
## 6  29 182      0 combination 43  Male  hispanic          ft          30
##   levelSmoking ageGroup2 ageGroup4 priorAttempts longestNoSmoke grp_num
## 1      heavy      21-49      35-49           0              0         0
## 2      heavy      21-49      35-49           3             90         0
## 3      heavy      21-49      21-34           3             21         1
## 4      heavy       50+      50-64           0              0         1
## 5      heavy      21-49      35-49           0              0         1
## 6      heavy      21-49      35-49           2            1825         1
```

```
str(smoking)
```

```
## 'data.frame':    125 obs. of  15 variables:
## $ id      : int  21 113 39 80 87 29 16 35 54 70 ...
## $ ttr      : int  182 14 5 16 0 182 14 77 2 0 ...
## $ relapse  : int   0 1 1 1 1 0 1 1 1 1 ...
## $ grp      : Factor w/ 2 levels "patchOnly","combination": 1 1 2 2 2 2 1 1 1 1 .
## $ age      : int   36 41 25 54 45 43 66 78 40 38 ...
## $ gender   : Factor w/ 2 levels "Female","Male": 2 2 1 2 2 2 2 1 1 2 ...
## $ race     : Factor w/ 4 levels "black","hispanic",...: 4 4 4 4 4 2 1 1 1 1 ...
## $ employment : Factor w/ 3 levels "ft","other","pt": 1 2 2 1 2 1 3 2 1 1 ...
## $ yearsSmoking : int   26 27 12 39 30 30 54 56 25 23 ...
## $ levelSmoking : Factor w/ 2 levels "heavy","light": 1 1 1 1 1 1 1 2 1 2 ...
## $ ageGroup2  : Factor w/ 2 levels "21-49","50+": 1 1 1 2 1 1 2 2 1 1 ...
## $ ageGroup4  : Factor w/ 4 levels "21-34","35-49",...: 2 2 1 3 2 2 4 4 2 2 ...
## $ priorAttempts : int   0 3 3 0 0 2 0 10 4 10 ...
## $ longestNoSmoke: int   0 90 21 0 0 1825 0 15 7 90 ...
## $ grp_num    : num   0 0 1 1 1 1 0 0 0 0 ...
```

3.6.3 Thống kê mô tả

```
overall_summary <- data.frame(
  So_quan_sat = nrow(smoking),
```

```

So_tai_phat = sum(
  smoking$relapse == 1,
  na.rm = TRUE
),
So_kiem_duyet = sum(
  smoking$relapse == 0,
  na.rm = TRUE
),
Trung_vi_thoi_gian = median(
  smoking$ttr,
  na.rm = TRUE
)
)

kable(
  overall_summary,
  caption = "Thống kê tổng quát của dữ liệu pharmacoSmoking"
)

```

Table 1: Thống kê tổng quát của dữ liệu pharmacoSmoking

So_quan_sat	So_tai_phat	So_kiem_duyet	Trung_vi_thoi_gian
125	89	36	49

```

group_summary <- do.call(
  rbind,
  lapply(
    split(smoking, smoking$grp),
    function(d) {
      data.frame(
        N = nrow(d),
        Relapse = sum(
          d$relapse == 1,
          na.rm = TRUE
        ),
        Censored = sum(
          d$relapse == 0,
          na.rm = TRUE
        ),
        Median_ttr = median(
          d$ttr,
          na.rm = TRUE
        )
      )
    }
  )
)

```

```

    )
  }
)
)

group_summary$Group <- rownames(group_summary)
rownames(group_summary) <- NULL

group_summary <- group_summary[
  ,
  c(
    "Group",
    "N",
    "Relapse",
    "Censored",
    "Median_ttr"
  )
]

kable(
  group_summary,
  caption = "Thống kê theo nhóm điều trị"
)

```

Table 2: Thống kê theo nhóm điều trị

Group	N	Relapse	Censored	Median_ttr
patchOnly	64	52	12	23
combination	61	37	24	65

4 Time-to-default for bank loans in survival analysis

4.1 Data Preparing

```

# Đọc dữ liệu từ file CSV
df <- read.csv("loans-data.csv", stringsAsFactors = FALSE)

# Chuẩn hóa dữ liệu
df <- as.data.frame(df)
df$low_savings <- ifelse(df$savings == "... < 100 DM", 1, 0)
df$short_emp <- ifelse(df$employment_history %in% c("... < 1 year", "unemployed"), 1, 0)
df$log_credit <- log(df$credit_amount)

```

```
head(df)
```

```
##   id default duration_in_month
## 1  1       0                6
## 2  2       1               48
## 3  3       0               12
## 4  4       0               42
## 5  5       1               24
## 6  6       0               36
##
##                                     credit_history
## 1 critical account/ other credits existing (not at this bank)
## 2                                     existing credits paid back duly till now
## 3 critical account/ other credits existing (not at this bank)
## 4                                     existing credits paid back duly till now
## 5                                     delay in paying off in the past
## 6                                     existing credits paid back duly till now
##
##                                     purpose credit_amount savings
## 1 domestic appliances          1169 unknown/ no savings account
## 2 domestic appliances          5951      ... < 100 DM
## 3 (vacation - does not exist?)    2096      ... < 100 DM
## 4 radio/television              7882      ... < 100 DM
## 5 car (new)                     4870      ... < 100 DM
## 6 (vacation - does not exist?)    9055 unknown/ no savings account
##   employment_history      personal_status_sex other_debtors
## 1 .. >= 7 years          male : single      none
## 2 1 <= ... < 4 years female : divorced/separated/married      none
## 3 4 <= ... < 7 years          male : single      none
## 4 4 <= ... < 7 years          male : single      guarantor
## 5 1 <= ... < 4 years          male : single      none
## 6 1 <= ... < 4 years          male : single      none
##
##                                     property age housing
## 1                                     real estate 67      own
## 2                                     real estate 22      own
## 3                                     real estate 49      own
## 4 if not A121 : building society savings agreement/ life insurance 45 for free
## 5                                     unknown / no property 53 for free
## 6                                     unknown / no property 35 for free
##   credits_this_bank      job
## 1      2 skilled employee / official
## 2      1 skilled employee / official
## 3      1      unskilled - resident
## 4      1 skilled employee / official
## 5      2 skilled employee / official
## 6      1      unskilled - resident
##
##                                     telephone foreign_worker low_savings
```

```
## 1 yes, registered under the customers name      yes      0
## 2                      none                     yes      1
## 3                      none                     yes      1
## 4                      none                     yes      1
## 5                      none                     yes      1
## 6 yes, registered under the customers name      yes      0
## short_emp log_credit
## 1          0    7.063904
## 2          0    8.691315
## 3          0    7.647786
## 4          0    8.972337
## 5          0    8.490849
## 6          0    9.111072
```

4.2 Exploratory Survival Structure

4.2.1 Kaplan-Meier estimate

```
km_fit <- survfit(Surv(duration_in_month, default) ~ 1, data = df)
# Xem bảng chi tiết tại một số mốc thời gian trọng yếu (6, 12, 18, 24, 36, 48, 60 tháng)
summary(km_fit, times = c(6, 12, 18, 24, 36, 48, 60))
```


```
## Call: survfit(formula = Surv(duration_in_month, default) ~ 1, data = df)
##
##   time n.risk n.event survival std.err lower 95% CI upper 95% CI
##    6     993      9   0.991 0.00301   0.9851      0.997
##   12     820     67   0.913 0.00955   0.8946      0.932
##   18     567     56   0.827 0.01399   0.7997      0.855
##   24     414     66   0.699 0.01869   0.6632      0.737
##   36     170     57   0.497 0.02634   0.4479      0.551
##   48      64     37   0.248 0.03192   0.1926      0.319
##   60      14      7   0.133 0.03620   0.0778      0.227
```

Mức độ sụt giảm cụ thể tại các cột mốc chính

- Tháng 12 ($\approx 91.3\%$): Trong 1 năm đầu tiên, khoảng 91.3% khoản vay duy trì an toàn. Rủi ro vỡ nợ sớm (Early Default) ở giai đoạn này chủ yếu đến từ khâu thẩm định ban đầu hoặc thông tin khai báo chưa chính xác.
- Tháng 24 ($\approx 69.9\%$): Sau 2 năm, xác suất sống sót giảm mạnh xuống 69.9% (đây là mốc ghi nhận số lượng ca vỡ nợ tuyệt đối lớn nhất - 66 ca).
- Tháng 36 ($\approx 49.7\%$): Đến mốc 3 năm, chưa đến một nửa số khoản vay dài hạn duy trì được trạng thái không vỡ nợ.

Kaplan-Meier survival curves

```
plot(
  km_fit,
  col = "blue",
  lwd = 2,
  xlab = "Time (Months)",
  ylab = "S(t)",
  main = "Kaplan-Meier Curve"
)
grid()
```



Nhận xét:

- Xác suất sống sót $S(t)$: Là xác suất khoản vay duy trì trạng thái an toàn (chưa vỡ nợ) tính đến thời điểm t tháng.
- Xu hướng sụt giảm: Bắt đầu tại $S(0) = 1.0$ (100% an toàn) và giảm dần theo thời gian do rủi ro tích lũy gia tăng.

- Đặc trưng dạng bậc thang (Step-function): Sụt giảm tập trung tại các kỳ hạn thanh toán chuẩn của hợp đồng (12, 18, 24, 36, 48 tháng) phản ánh các thời điểm đáo hạn, trả gốc/lãi định kỳ hoặc kết thúc khoảng thời gian ân hạn. Đây là những cột mốc khách hàng chịu áp lực tài chính lớn nhất, dẫn đến hiện tượng vỡ nợ tập trung bùng phát theo từng chu kỳ.

4.2.2 Nelson-Aalen estimate


```
na_fit <- survfit(Surv(duration_in_month, default) ~ 1, data = df, type = "fh")
# Xem bảng chi tiết tại một số mốc thời gian trọng yếu (6, 12, 18, 24, 36, 48, 60 tháng)
summary(na_fit, times = c(6, 12, 18, 24, 36, 48, 60))
```

```
## Call: survfit(formula = Surv(duration_in_month, default) ~ 1, data = df,
##      type = "fh")
##
##   time n.risk n.event survival std.err lower 95% CI upper 95% CI
##    6      993       9   0.991 0.00301   0.9851      0.997
##   12      820      67   0.913 0.00954   0.8946      0.932
##   18      567      56   0.827 0.01398   0.7998      0.855
##   24      414      66   0.699 0.01868   0.6635      0.737
##   36      170      57   0.498 0.02631   0.4487      0.552
##   48       64      37   0.250 0.03189   0.1946      0.321
##   60       14       7   0.138 0.03610   0.0823      0.230
```

Kaplan-Meier survival curves

```
plot(
  na_fit,
  col = "red",
  lwd = 2,
  xlab = "Times (Month)",
  ylab = "S(t)",
  main = "Nelson-Aalen Curve"
)
grid()
```

Nelson–Aalen Curve



Nhận xét:

- Đường $S_{NA}(t)$ có dạng bậc thang giảm dần tương tự đường Kaplan-Meier, phản ánh sự tích lũy rủi ro vỡ nợ tăng dần theo kỳ hạn khoản vay.
- Giai đoạn đầu ($t \leq 12$ tháng): Đường cong giảm nhẹ, xác suất an toàn duy trì ở mức cao ($\approx 91.5\%$). Rủi ro vỡ nợ sớm ở giai đoạn này là tương đối thấp.
- Giai đoạn giữa ($t = 12 \rightarrow 36$ tháng): Đồ thị xuất hiện các bước sụt giảm lớn và dốc. Tỷ lệ an toàn giảm mạnh xuống còn khoảng 71% ở tháng 24 và chỉ còn khoảng 52% ở tháng 36.
- Giai đoạn cuối ($t > 36$ tháng): Mức độ sụt giảm đi vào ổn định do số lượng khoản vay còn hoạt động trong tập nguy cơ giảm dần.

4.3 Một số ứng dụng cho models

Dựa trên kết quả từ các đường cong sống sót phi tham số (Kaplan-Meier, Nelson-Aalen) và mô hình rủi ro tỷ lệ Cox thu được ở các phần trước, nhóm đưa ra một số nhận xét nghiệp vụ và đề xuất cụ thể cho công tác quản lý rủi ro khoản vay như sau:

4.3.1 Xác định thời điểm phát cảnh báo sớm (Early Warning System - EWS)

Trong quản trị tín dụng, việc chủ động phát hiện sớm khoản vay có nguy cơ vỡ nợ giúp ngân hàng giảm thiểu đáng kể chi phí trích lập dự phòng và tỷ lệ nợ xấu.

- Thời điểm đề xuất cảnh báo: Chuyên viên quản lý rủi ro nên thực hiện rà soát và phát cảnh báo sớm trong khoảng từ 1 đến 3 tháng trước các mốc 12, 24 và 36 tháng kể từ thời điểm giải ngân (tương ứng vào tháng thứ 9–11, 21–23, và 33–35).
- Cơ sở từ dữ liệu:
 - Quan sát các đồ thị ước lượng $\hat{S}(t)$ từ cả hai phương pháp Kaplan-Meier và Nelson-Aalen, nhận thấy xác suất sống sót không giảm đều mà xuất hiện các bước sụt giảm mạnh nhất tại các cột mốc tròn năm (tháng 12, 24, và 36).
 - Trong thực tế, các thời điểm này thường trùng với kỳ điều chỉnh lãi suất, kỳ hạn trả gốc định kỳ hoặc thời điểm khách hàng gặp áp lực quay vòng dòng tiền.
 - Việc phát cảnh báo sớm trước 1–3 tháng tạo khoảng thời gian cần thiết để chuyên viên tín dụng kiểm tra lại tình hình tài chính của khách hàng, nhắc nợ hoặc tính toán phương án cơ cấu lại thời hạn trả nợ trước khi biến cố vỡ nợ thực sự xảy ra.

4.3.2 Diễn giải survival probability cho nhóm khách hàng có rủi ro cao

Xét trường hợp một khách hàng có hồ sơ đầu vào chứa các yếu tố bất lợi bao gồm: số tiền vay lớn (**high credit amount**), tiền tiết kiệm thấp (**low savings**) và thâm niên làm việc ngắn (**short employment history**).

Từ kết quả mô hình Cox Proportional Hazards, xác suất sống sót của khoản vay này được giải thích như sau:

1. Về hình dạng đường cong sống sót:

- Đường xác suất sống sót $S(t)$ của nhóm khách hàng này dốc xuống rất nhanh so với đường trung bình của toàn bộ danh mục.
- Ngay trong 12 tháng đầu tiên, xác suất khoản vay tiếp tục duy trì trạng thái an toàn đã bị sụt giảm mạnh, thể hiện nguy cơ vỡ nợ sớm (**early default**) ở mức cao.

2. Tác động từ các biến số (Giải thích qua Hazard Ratio):

- **high credit amount** ($\log(\text{credit})$ lớn): Số tiền vay càng lớn thì nghĩa vụ trả gốc và lãi định kỳ hàng tháng càng cao, tạo áp lực liên tục lên dòng tiền của người vay.
- **low savings & short employment history**: Thâm niên công tác ngắn phản ánh nguồn thu nhập chưa thực sự ổn định. Khi kết hợp với mức tiết kiệm thấp, khách hàng gần như không có lớp đệm tài chính (**financial buffer**) để ứng phó nếu gặp sự cố đột xuất (như mất việc hoặc giảm thu nhập).
- Sự kết hợp của 3 yếu tố này làm chỉ số nguy cơ $h(t)$ tăng vọt, dẫn đến Tỷ lệ Nguy cơ (**Hazard Ratio - HR**) của nhóm này cao vượt trội so với các khách hàng có hồ sơ tích cực.

3. Đề xuất xử lý:

- Khách hàng thuộc nhóm hồ sơ này có xác suất duy trì khoản vay đến hết kỳ hạn mà không vỡ nợ là rất thấp.
- Do đó, hệ thống phê duyệt cần xếp khách hàng vào phân khúc rủi ro cao để cân nhắc các biện pháp kiểm soát: giảm tỷ lệ cho vay (LTV), yêu cầu bổ sung tài sản đảm bảo hoặc áp dụng mức lãi suất cộng thêm tương ứng với mức độ rủi ro.

5 Tài liệu tham khảo

- [1] Moore, D. F. (2016). Applied Survival Analysis Using R. Springer International Publishing.
- [2] T. Therneau, C. Crowson, and E. Atkinson, “Using time dependent covariates and time dependent coefficients in the Cox model,” Mayo Clinic, R package survival vignette, Jan. 2026.